Relatório 4 - Prática: Principais Bibliotecas e Ferramentas Python para Aprendizado de Máquina (I)

Matheus Beuren Carvalho

1. Introdução

O objetivo deste card, é o aprendizado de bibliotecas e ferramentas para Ciência de Dados e Machine Learning, citado pelo card como fundamental para o laboratório. A atividade consiste em instalar o Jupyter Notebook, aprender a biblioteca Numpy e a biblioteca Pandas, com exercícios ao final da seção.

2. Desenvolvimento

2.1 Seção 3 - Jupyter Notebook

Esta seção ensina a instalação e como usar o Jupyter Notebook, também demonstra a utilização de ambientes virtuais. Realizei as tarefas das próximas seções, utilizando o VS Code com Anaconda, e o arquivo notebook.

2.2 Seção 5 - Python para Análise de dados - Numpy

O vídeo aborda primeiramente conhecimentos referentes a criação de arrays e matrizes, juntos às funções de criação de números aleatórios. Também, foi apresentado funções como o shape e o reshape(), que são responsáveis por ver e mudar o tamanho da matriz, array ou dataframe. O fatiamento em python, traz uma funcionalidade muito importante, que facilita a divisão da matriz ou tabela, entre outros, por meio de índices. As, funções de média, desvio padrão, mínimo e máximo, permitem a utilização de vários recursos importantes para o uso na área de dados.

O numpy na área de dados, é principalmente colocado em prática na engenharia de dados, onde é feita toda a manipulação, transformação e preparação do dataset, geração de dados simulados e tratamento de NaN, que são uma das partes principais a se resolver.

2.3 Seção 6 - Python para Análise de dados - Pandas

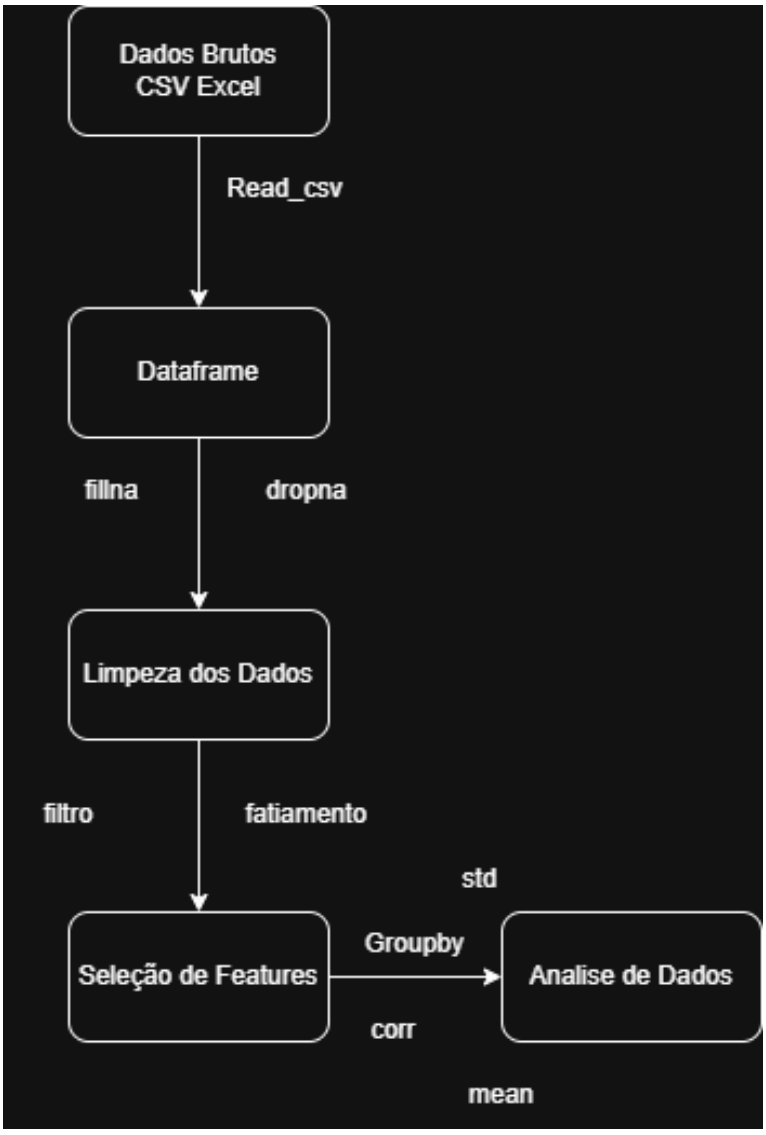
O Series é a estrutura unidimensional do Pandas com índices nomeados, e operações entre Series com índices diferentes resultam em NaN.

O Data Frame, é uma forma de organizar os dados em forma de tabela, podendo utilizar as principais funções do pandas, muito utilizado na área de dados para representar datasets. O loc facilita a localização por índice, e filtros booleanos (&, |) permitem selecionar dados por condição. O dropna e fillna tratam valores NaN, e groupby agrupa dados por coluna e também pode receber filtros dependendo da situação.

As funções que juntam e concatenam dois dataframes, são essenciais para a junção de dois datasets ou grupos distintos. As operações, são as principais formas de obter análises concretas ao manipular dataframes, dentre elas as mais utilizadas são o unique(conta quantos valores sao unicos), value_counts(conta os valores totais), apply(aplica uma função específica para linha ou coluna), isnull(paa verificar se tem dados faltantes no data frame) e uma das mais poderosas o pivot_table que cruza dados de um data frame.

Em seguida, na **Figura 1** o fluxograma define uma sequência básica para a engenharia de dados com as funções passadas no curso.

Figura 1 - Fluxograma



Finalizando a seção de Pandas, funções que leem um arquivo csv ou planilha de excel, e até em html para fazer um web scraping, serão muito utilizadas para trabalhos futuros diante do conteúdo do bootcamp. Além disso, destaco a usabilidade das duas bibliotecas, que são muito importantes e sem dúvidas essenciais para trabalhar com ciência de dados e Machine Learning.

3. Conclusão

O Numpy e o Pandas, são duas bibliotecas muito importantes para a área de ciência de dados, pois na engenharia de dados, onde ocorre o tratamento e a seleção de features, são necessárias ferramentas versáteis e rápidas. Hoje, são as duas bibliotecas principais para a ciência de dados, indispensáveis para qualquer profissional na área.