Relatório 5 - Prática: Estatística p/ Aprendizado de Máquina (I)

Matheus Beuren Carvalho

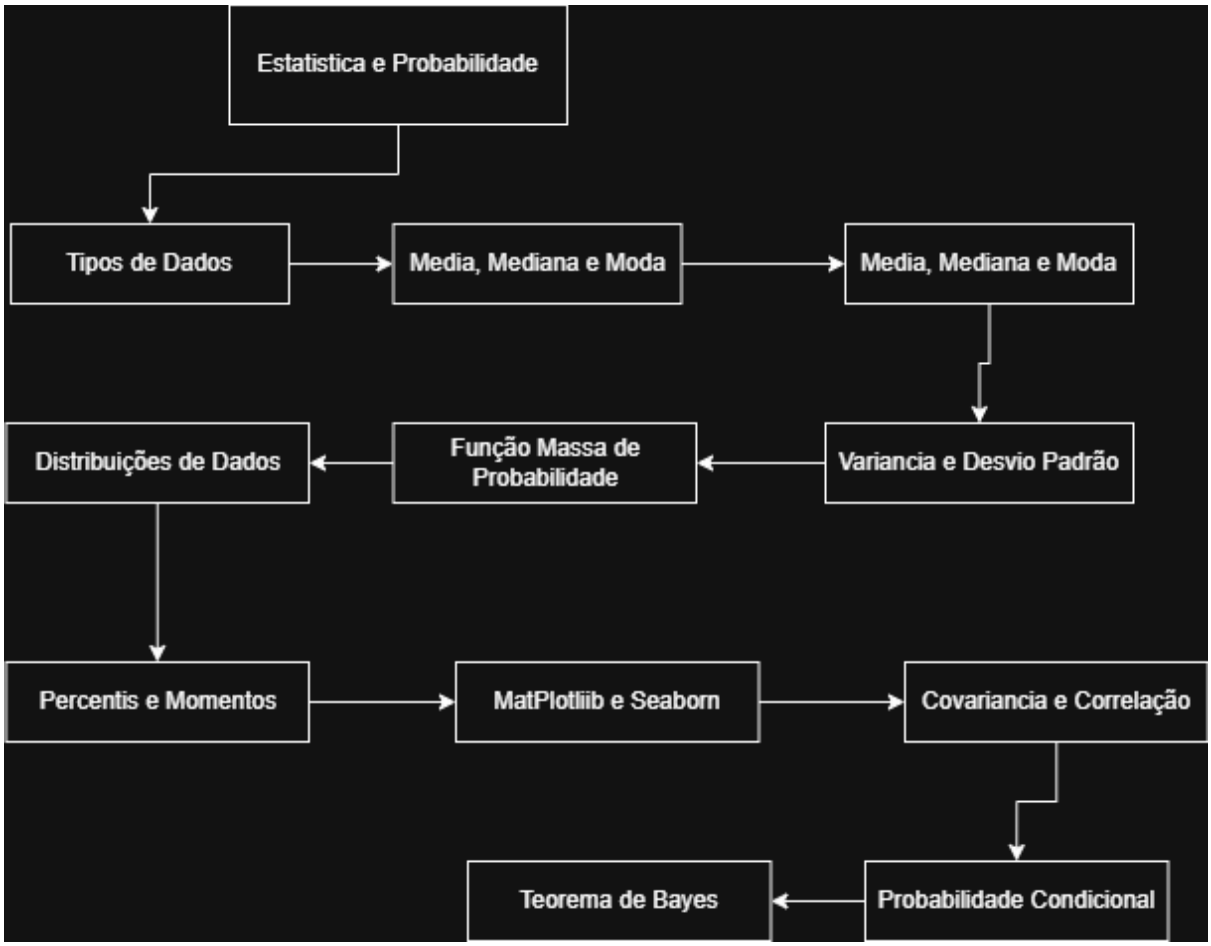
1. Introdução

Este card, dá a tarefa de assistir o mini curso de Estatística e Probabilidade, sendo um dos principais pontos para ciência de dados e machine learning. A seguir será feito o relatório com os principais pontos aprendidos neste mini curso.

2. Desenvolvimento

A seguir na **Figura 1**, o diagrama do curso com os principais tópicos.

Figura 1 - Principais tópicos abordados no curso.



Em primeiro plano, é apresentado os tipos de dados que iremos encontrar durante o ciclo de data science e machine learning, entre eles estão: numérico, categórico, e Ordinal

- Numérica: categoria que pode quantificar dados, a discreta se baseia na contagem de um evento(inteira), e a contínua assume qualquer valor decimal dentro de um intervalo(decimais);
- Categórica: tem como objetivo dividir dados em categorias;
- Ordinal: são uma mistura dos tipos numérico e dos tipos categóricos.

Dando sequência ao curso, foi ensinado conceitos de operações matemáticas, como a média, mediana, moda, que são recursos extremamente utilizados na análise de dados e até no tratamento de dados onde precisa ser colocado valores em NaN com base na média ou mediana em relação a coluna do dataframe. A média é a soma de todos os elementos e depois dividido pela quantidade de números, a mediana pega o número que está meio de um array, por exemplo, sempre chegando a dois números centrais ou somente um, e por fim, a moda é o número que mais aparece diante seus dados.

A variância dos dados pode ser um insight valioso para o analista de dados, saber quanto varia em relação a média. É isso que a variância mede, o quanto um dado está longe da média. Em seguida, o desvio padrão é uma fórmula que calcula a dispersão dos dados em relação à média, onde um valor baixo aponta que o valor está próximo à média, e um longe indica que está distante da média.

Uma função de probabilidade densidade é uma curva sólida que descreve a probabilidade de uma faixa de valores ocorrer com dados contínuos

Distribuição estatística é o jeito como os valores de uma variável se espalham, ou seja, mostra quais valores aparecem mais e quais são mais raros de acontecer. Cada tipo de distribuição descreve um padrão diferente: a Normal é aquele formato de sino simétrico em torno da média, já a Poisson serve para contar eventos raros dentro de um intervalo de tempo, e assim segue com a Binomial, a Exponencial e as outras.

Os percentis são medidas utilizadas para dividir um conjunto de dados em 100 partes, resultando em 1% do total, por exemplo, se um certo valor está no percentil 70, quer dizer que 70% dos dados são menores ou iguais ao elemento, sendo o resto maior. Seguindo a aula, é apresentado conceito de momentos em estatística, separados em 4 momentos:

- 1° Momento: é relacionado a média, mde o ponto de equilíbrio dos dados;
- 2° Momento: a variância calcula a média da distância em relação à média;
- 3° Momento: a assimetria avalia a falta de distribuição na cauda, sendo ela para a direita é positiva, se for a esquerda é negativa;
- 4° Momento: calcula o achatamento da curva, o que indica uma grande quantidade nos extremos.

Em relação a covariância, ela mede o quanto duas variáveis se parecem, ou melhor, se elas andam juntas, um exemplo é, o preço de uma casa pode aumentar conforme a localidade em uma cidade, nesse caso o preço e a localidade andam juntas. Porém, a correlação é a covariância normalizada, indo de 1 até -1, quanto

mais próximo de 1, mais forte é a correlação, próximo a 0 significa que não tem correlação, e quanto mais próximo de -1 mais negativa forte, ou seja, quando uma sobe a outra desce.

Na probabilidade condicional, mede qual a chance de um evento X acontecer sendo que um evento Y já aconteceu. Os eventos são independentes, se um evento não altera a chance de um outro acontecer. Nisso, também é abordado o teorema de Bayes, que por sua vez usa a probabilidade condicional para saber se um evento de chance de acontecer, porém no teorema é adicionado outros eventos ou evidências para ver se a chance mudar conforme novas features.

3. Conclusão

A estatística para Machine Learning e Ciência de dados é indispensável, sendo um dos pilares principais para analisar os dados, treinar modelos com base em uma feature alvo, mas antes vem a análise de relação, nisso é visto se as features dependem uma das outras, para assim fazer a seleção das features para treinar o modelo. Esta parte de estatística, está mais presente na análise dos dados em geral, sendo muito importante para os cientistas de dados.