

Relatório 14 - Prática: Redes Neurais (II)

Matheus Beuren Carvalho

1. Introdução

O desenvolvimento deste card se baseia no aprendizado de redes neurais artificiais, onde ao longo das seções serão abordados temas como: classificação binária, classificação multiclases e regressões. Este relatório aborda os principais conceitos aprendidos no decorrer do curso e aborda temas muito interessantes.

2. Desenvolvimento

Um neurônio artificial é composto com 3 componentes principais, dentre eles estão as entradas, os pesos e a função de somatório e step function. Após as funções serem realizadas, a step function interpreta o resultado como um número menor ou igual a zero, sendo a saída 0, se o número é maior ou igual a um, a saída é um. O cálculo para prever uma classe se baseia no resultado de cada neurônio com operadores lógicos como o E e o OU.

A taxa de aprendizagem foi um conceito abordado como essencial para o tratamento de erros e aumentar a taxa de acertos. A fórmula se baseia na saída da rede neural, onde o erro é baseado na classe esperada menos a classe prevista, com base na saída a fórmula de taxa de aprendizado é aplicada para cada linha.

$$peso(n + 1) = peso(n) + (taxaAprendizagem * entrada * erro)$$

Redes Multicamadas é composta por mais de uma camada de neurônios, após isso passa por uma ou mais camadas ocultas recebendo a entrada de cada neurônio anterior junto ao peso de ligação tendo como resultado do somatório o valor do neurônio. Após o cálculo de cada somatório, é feita a função de ativação que calcula com base na função definida, no caso do vídeo Sigmóide, assim tendo o resultado final entre 0 e 1.

O algoritmo Backpropagation, resolve um problema que o perceptron faz, que é o cálculo de erro das camadas ocultas. Em redes artificiais, o perceptron calcula o erro com base no previsto comparado ao esperado, porém em redes multi camadas as camadas ocultas não tem um valor definido somente as de saídas, então por isso o backpropagation faz o retorno calculando pelo delta o quando esse neurônio ajudou para o erro final, fazendo esse processo até chegar nas entradas, assim tendo todos os pesos ajustados.

$$peso(n + 1) = peso(n) * momento + entrada * delta * taxaAprendizagem$$

Conceito	Descrição
BIAS	Permite com que o neurônio dispare mesmo se as entradas forem zeros. Um peso adicional antes da função de ativação.
MSE	Eleva ao quadrado os erros antes de tirar a média. FAZ com que erros maiores sejam penalizados
RMSE	Raiz quadrada do MSE. Traz os números para a escala inicial.
Batch gradient descent	Calcula o erro para todos os registros e depois ajusta os pesos
Stochastic gradient descent	Calcula o erro para cada registro e depois ajusta os pesos.

O cross-validation é uma técnica que pode substituir a divisão tradicional dos dados, ele verifica K combinações de dados para treinar e validar o modelo. Ele é utilizado para não ocorrer o caso de a divisão tradicional perder um dado muito importante para o treinamento do modelo.


Em treinamentos de modelos de aprendizado de máquina, dois problemas principais afetam este treinamento, são eles o overfitting e underfitting. O overfitting é quando um modelo não se generaliza bem, ou seja, o modelo tem uma acurácia muito boa no treinamento e uma acurácia ruim em teste, quer dizer que o modelo decorou ou não aprendeu os padrões. O underfitting é quando você tenta usar um modelo muito fraco para um problema complexo, onde também tem uma acurácia péssima no treinamento e razoavelmente boa nos testes.

O fine tuning é um método de treinamento onde é usado o cross-validation junto com um conjunto de parâmetros para descobrir os melhores parâmetros para treinar o modelo. O melhor modelo se define pela maior acurácia encontrada nos modelos com melhores parâmetros.

A classificação binária é a saída de classes onde correspondem se um determinado valor é 0 ou 1, por exemplo, hoje vai chover (Sim ou Não). Em deep learning, esta classificação pode ser usada em apenas 2 classes, sendo o resultado

único que correspondente a uma das duas classes. A seguir, a rede neural que usei no notebook de pratica.

Figura 1 - Rede Neural Prática



A parte prática se resumiu em utilizar um dataset do kaggle, onde o objetivo é prever se uma pessoa possui diabetes ou não com base em 8 features. Referente ao treinamento do modelo foi necessário utilizar uma normalização nos dados para que o modelo pudesse ter uma melhor acurácia. Ao final do treinamento obteve-se uma acurácia de 76% de acertos, um resultado consideravelmente bom, porém para o escopo das aulas onde foi aprofundado em modelos básicos de rede neural esse foi o melhor resultado. A possível causa de uma acurácia baixa nos treinos, na minha interpretação é causada por underfitting, onde o modelo não consegue achar um padrão nos dados, ou seja, muito fraco.

As redes neurais multiclasse são usadas quando é utilizado mais de dois neurônios de saída, ou seja, mais de 2 classes para decidir. Exemplo da prática feita para a aula, três saídas para diferentes classes, então a rede calculava e dava a probabilidade por classe usando o softmax.

O One Hot Encoder faz a transformação de colunas categorias do tipo string para o tipo numérico, para assim o modelo de fato entender os dados. Seu diferencial, é que comparado a outros transformers como por exemplo o Label Encoder, ele não coloca pesos ou hierarquia nas categorias, ele cria uma coluna com um código diferente para cada registro diferente. Ele foi utilizado na seção de

regressão, onde era necessário transformar colunas em números para assim categorizar cada tipo.


A regressão com múltiplas saídas segue a mesma estrutura da com uma saída e por isso no desenvolvimento fez somente a de múltiplas saídas, pois elas seguem o mesmo padrão. Sua definição é que ao contrário da tradicional regressão essa retorna mais de um valor ao mesmo tempo, como por exemplo na prática que foi executada, diante um dataset que tem várias características dos alunos e suas notas em diferentes períodos. Nisso, após o treinamento da rede foi feito uma predição das tres variaveis target e foi utilizada a metrica MAE(mean absolute error) para comparar os resultados da predição com os dados reais, os resultados podem ser vistos na Tabela 1.

Tabela 1 - Resultados obtidos na regressão múltipla

	1° Período(y1)	2° Período(y2)	3° Período(y3)
Média Real	11.39	11.57	11.90
Predição	11.11	11.28	11.58
MAE	1.37	1.42	1.61

Interpretando o MAE, ele nos diz o quando o modelo pode errar tanto negativamente quanto positivamente. A seguir uma visualização das saídas da rede neural da prática.

Figura 2 - Rede com múltiplas saídas



(diminui os neurônios para não poluir a imagem)

3. Conclusão

As redes neurais são uma imitação do cérebro humano, com vários neurônios conectados compartilhando informações entre si. A complexidade dos dados pode ser facilmente destrinchada pela rede neural pela sua capacidade de aprofundar e aumentar a rede e seus neurônios. O conteúdo em si é muito interessante pelo fato de tudo se conectar e além disso, ser a base para modelos de visão computacional onde invés de dados tabulares, são usados imagens para o treino de modelos