Relatório 16 - Prática: Redes Neurais Convolucionais 1 (Deep Learning) (II)

Matheus Beuren Carvalho

1. Introdução

Este card está relacionado ao conteúdo de redes neurais, mais especificamente redes neurais convolucionais(CNN). Este relatório se refere aos principais conceitos que aprendi durante o curso deste conteúdo. A parte mais desafiadora que passei, foi entender as quatro fases das redes convolucionais.

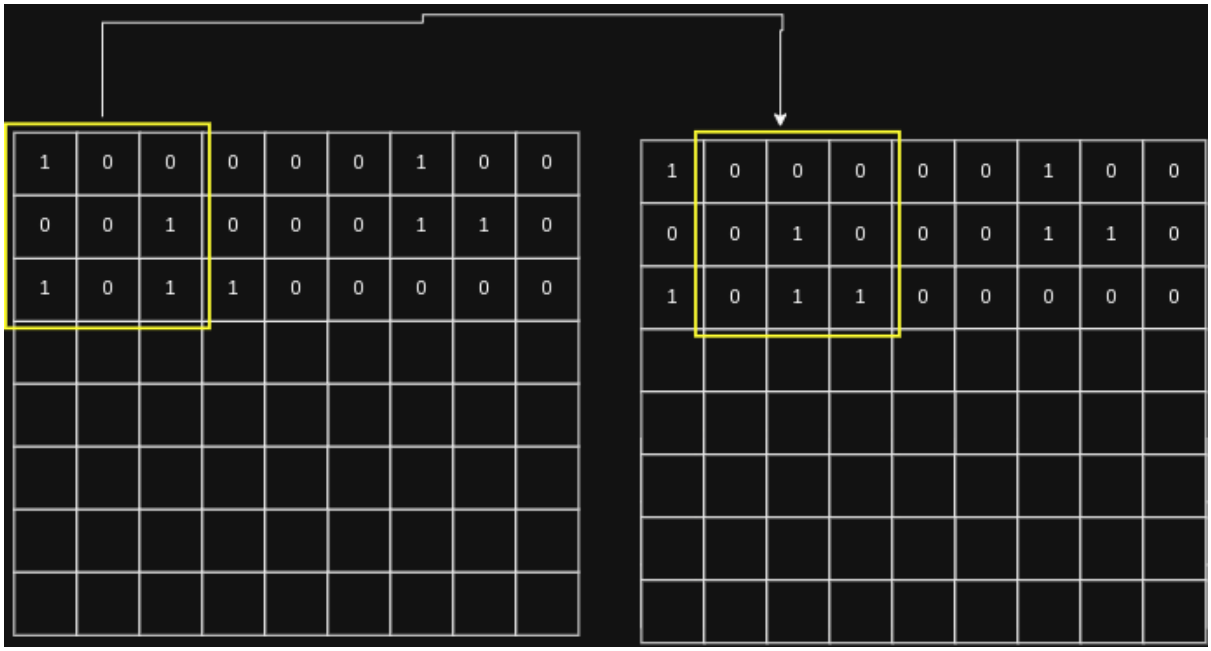
2. Desenvolvimento

Os pixels são o menor objeto de uma imagem, eles são quadrados onde dependendo da imagem possuem uma cor específica. As cores são definidas pelo RGB(red, blue, green), com essas três cores podemos ter qualquer cor, nisso cada cor terá um código específico. Com as cores definidas nos temos o tamanho da imagem em pixels multiplado multiplicado pelas três cores assim temos o tamanho da entrada da rede neural, porém isso pode acabar ficando pesado e atrapalhar o desempenho da rede, ao deixar a imagem com tons de cinza temos as três cores RGB com o mesmo valor, assim não precisamos inserir as três cores como entrada, assim diminuímos o processamento e aceleramos a performance.

Quando trabalhamos com redes convolucionais, não é necessário fazer a extração de características, pois a própria rede já faz isso nas etapas de pré processamento, utilizando como input somente os pixels necessários. A seguir os passos para fazer uma rede neural convolucional:

- Operador de convolução: uma matriz onde é multiplicada pela matriz de imagem, ela serve para extrair características;
- Pooling: diminui o tamanho da matriz, mas com as principais características, aquelas que diferenciam uma classe da outra;
- Flattening: pega a matriz das principais características do pooling, e transforma em um vetor que será utilizado nas entradas da rede;
- Rede neural densa: segue o mesmo padrão de rede das redes artificiais, porém retorna a probabilidade de cada classe.

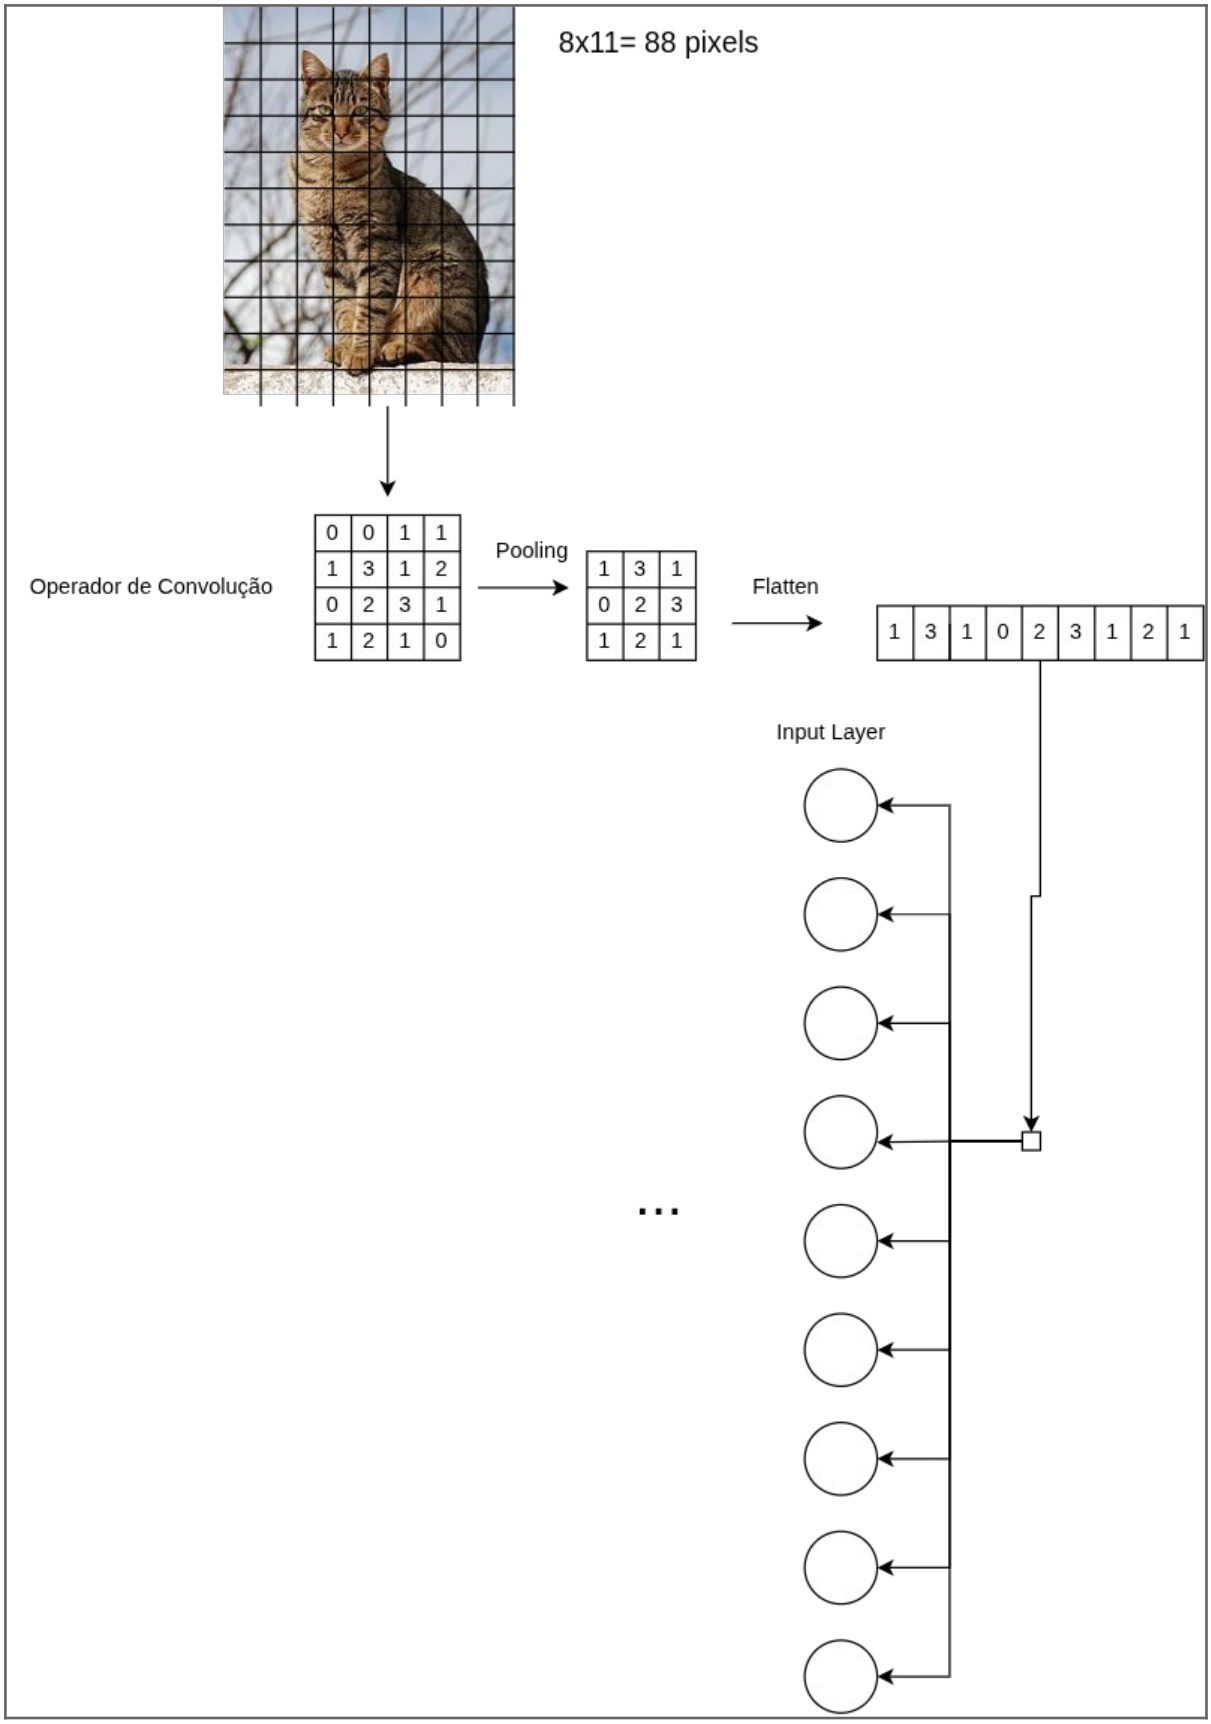
Figura 1 - Operador de convolução



O operador de convolução e polling utilizam a mesma maneira de percorrer a matriz, sempre que é extraído as características dado uma matriz 3x3 a matriz anda um pixel à direita.

Data Argumentation é um método que gera novas imagens a partir das já existentes, ela na teoria cria imagens que não podem ser visualizadas. Esse processo ocorre definindo parâmetros na função onde pode ser feito a rotação, zoom entre outro atributos que modificam a imagem, assim podendo ter uma base mais ampla quando se possui poucos dados. Porém, este método não substitui as imagens reais, o instrutor diz claramente no vídeo que o ideal é conseguir mais imagens reais o que pode aumentar muito o desempenho da rede se comparado usando o data argumentation.

Figura 2 - Fases de uma CNN



Na figura 2 podemos ver todas as fases de uma CNN, que diferente de uma rede neural artificial, tem métodos diferentes e maia avançados. Antes da primeira fase temos uma imagem(gato) dividida em pixel assim tendo uma dimensão da

imagem, além disso as entradas que dependem se a imagem está em RGB ou acinzentada. Seguindo para a primeira fase temos o operador de convolução que gera um, número N de filtros definido por parâmetro, assim gerando N matrizes pegando diferentes características específicas, em seguida o pooling pega os maiores números desses filtros e redimensiona para uma matriz menor, depois o Flatten transforma essa matriz em vetor para que seja usada na camada de entrada da rede. E por fim a entrada da rede que recebe um pixel para cada neurônio, depois seguindo o mesmo padrão de redes até a camada de saída que possui as classes.

3. Conclusão

Finalizando este relatório, podemos observar que o conteúdo de redes neurais vai muito além de somente predizer um número, mas sim classificar imagens e transformá-las em dados que a rede pode entender. A transformação das imagens é uma das coisas que mais fiquei impressionado, por conta de toda imagem se tratar de uma matriz de código de cor(RGB). Ao fim do curso consegui entender todos os conceitos e reproduzir um código por conta propria.