Relatório 17 - Prática: Redes Neurais Convolucionais 2 (Deep Learning) (II)

Matheus Beuren Carvalho

1. Introdução

Este relatório contém os principais conceitos aprendidos e entendimentos referente ao conteúdo de rede convolucionais(CNN). O conteúdo em questão se trata das redes aplicadas a imagens, diferente de cards anteriores que abordavam redes a partir de dados tabulares. Curso muito denso, porém muito bom de assistir e conceitos claros durante as aulas.

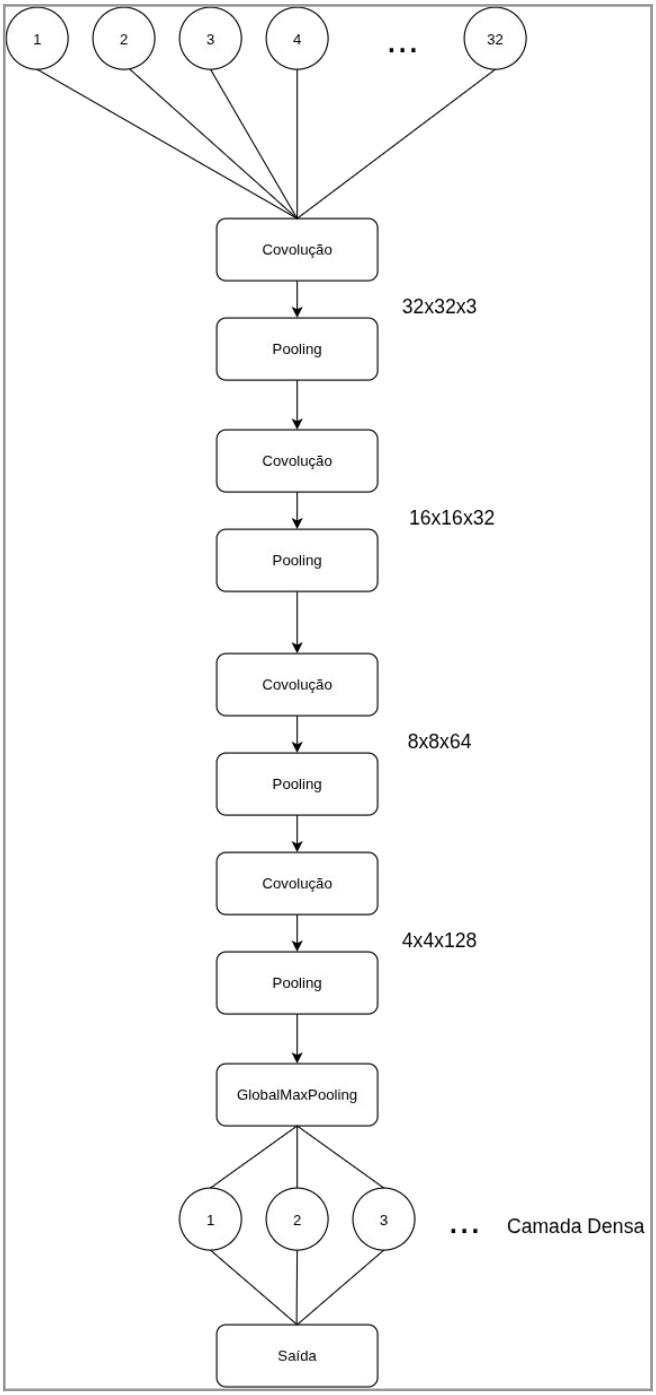
2. Desenvolvimento

As CNNs são tipos de rede que em sua maioria são aplicadas a imagens, e nesse processo de convolução existe o kernel(filtro) que é uma matriz menor que a imagem, onde passa em cada parte da imagem aplicando cálculos e assim aplicando um filtro, como por exemplo o blur. Quando tratamos uma imagem com somente tons de cinza, temos uma imagem 2d, diferentemente de quando utilizamos uma imagem 3d(RGB). A captação de features se deve a sua quantidade, se um filtro captura uma característica ou padrão, automaticamente se tiver mais filtros mais características serão extraídas, como por exemplo no reconhecimento facial onde é extraído o olho, nariz entre outras características. Com gradient descent, os pesos dos filtros são escolhidos automaticamente pela rede, assim como uma camada densa otimiza seus pesos.

O polling é uma forma de pegar somente as características necessárias dentro de uma imagem. Os tipos mais conhecidos são o Max Pooling e o Average Pooling, o max polling pega os maiores números dado uma matriz de seleção que é definida nos parâmetros. Já o Average Pooling é a média aritmética da matriz e o valor resultante é escolhido.

Alguns conceitos novos foram aprendidos nesta seção que em comparação com o card anterior não estavam presentes. A convolução strided, é uma alternativa do pooling onde você controla quantos passos a matriz de seleção no feature map anda, a justificativa para isso é que pixels próximos tendem a serem muito semelhantes. Outro ponto abordado é o GlobalMaxPolling, onde é utilizado para solucionar o problema do flatten, que transforma um objeto tridimensional, vindo das camadas de convolução e pooling, o problema disso é que quando utilizado tamanhos diferentes ele pode dar números inconsistentes como 1200 para 1800 dependendo da imagem e do feature map, nisso o globalmaxpolling pega o maior valor de cada feature map, assim tendo o mesmo tamanho de vetor a cada imagem, pois agora depende do tamanho de features maps.

Figura 1 - Arquitetura de uma CNN



Na figura 1, podemos analisar uma arquitetura seguindo alguns conceitos aprendidos em aula, como por exemplo mais camadas de filtro(convolução e pooling), pois com mais camadas é possível enxergar melhor as características conforme vai diminuindo a imagem.

Uma das principais vantagens na comparação de deep learning e machine learning, é que para deep learning a criação de novos dados favorece o modelo, diferente de machine learning que ao criar dados pode se anular um algoritmo, pois simular uma possível ação humana ou dados importantes, pode ter consequências trágicas. No entanto em deep learning é possível criar dados sem afetar o modelo, pois uma imagem pode ser rotacionada, movida para um lado, então essas modificações o modelo entende que se trata de uma imagem diferente.

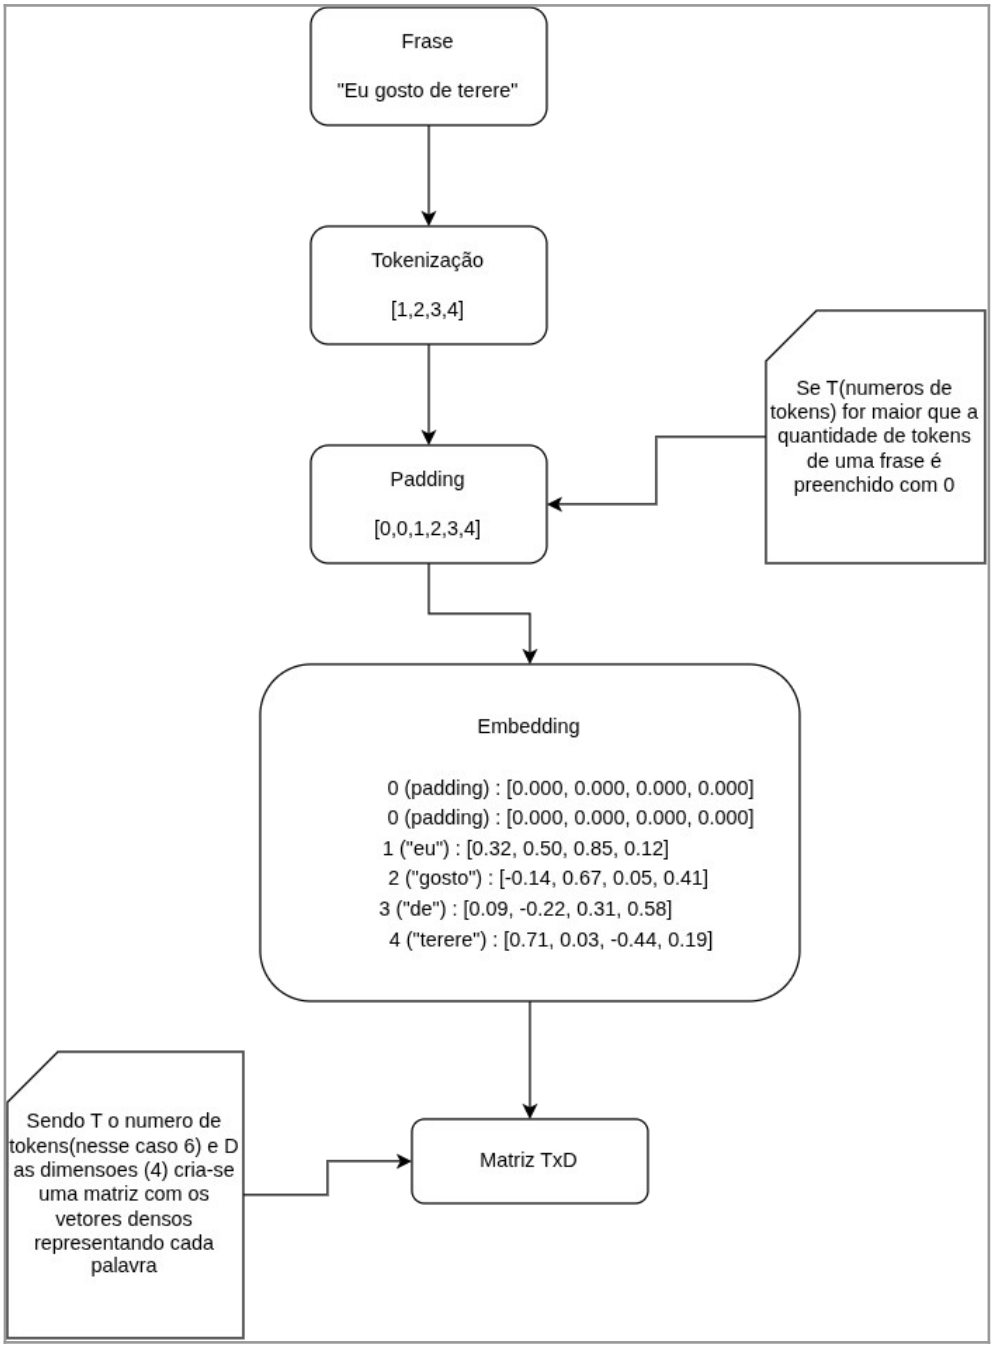
O BatchNormalization é utilizado para normalizar os dados quando há um desvio padrão muito grande. Ele pega a média e divide pelo desvio padrão, retornando números em torno de 0 e 1.

O embedding é um espaço dimensional onde cada palavra é atribuído pesos durante o treinamento da rede neural, posicionando palavras com o mesmo sentido próximas uma das outras.

No processamento de texto apresentado na seção de NLP, dada uma lista de frases, um tokenizador separa cada palavra e as ordena por frequência de vezes que aparecem nas frases, colocando índices inteiros crescentes a palavra mais frequente recebe o menor índice. Por exemplo, se 'eu' é a palavra que mais aparece nas frases, ela recebe o índice 1.

Para representar o fluxo de NLP, fiz um diagrama simples para simplificar o processo (Figura 2).

Figura 2 - Processo de NLP



Ao decorrer do código de prática da seção de NLP, vi uma oportunidade que não foi diretamente exposta em vídeo mas achei uma questão muito interessante de testar, se trata de um CNN com linguagem natural multiclasse. O dataset se trata de notícias, e o intuito é classificá-las nas seguintes áreas: Esporte, Mundo, Negócios e Ciência/Tecnologia. O modelo apresentou uma acurácia muito boa nas duas primeiras épocas e depois teve um overfitting muito brusco, nesse caso utilizei o batch normalization e o Dropout diminuíram drasticamente o overfitting.

No decorrer do curso, mas especificamente nas seções 7 e 8, foi apresentado um conteúdo mais de revisão e algumas convenções de como modelar e ver como funciona uma CNN.

O MSE(Mean Squared Error) é métrica que mede o quanto as previsões do modelo estão dos dados reais, seu significado é baseado na média das previsões do modelo menos os dados reais elevado ao quadrado. levar ao quadrado impede que dados como por exemplo “+2 + (-2) =0” dois erros se anulam, assim dado como erro zero onde na verdade os dois possuem erro, elevar ao quadrado faz com que exemplos como esse não se repitam. O Binary Cross-Entropy é utilizado para a classificação binária baseada em probabilidade e para problemas de classificação multiclasse é utilizado o Categorical Cross-Entropy.

Tabela 1 - Gradient Descent

	O que é	O que resolve
Gradient Descent	Algoritmo usado para treinar a maioria dos modelos de DL	MInimiza as funções de erro
Stochastic Gradient Descent	Calcula o gradiente do erro para amostras menores	O custo computacional para somar todos os dados de um dataset
Momentum	Ajusta os parâmetro com base em passos históricos, fazendo ele seguir na mesma direção	Acelera o processo de treino pois otimiza a descida do gradiente

3. Conclusão

Ao longo do card apresentei os conceitos que na minha visão são os principais para o curso em questão. Nisso eu destaco a profundidade do curso e como ele tem um conteúdo bastante abrangente sobre o CNNs, os tópicos abordados, principalmente NLP foi o que mais me chamou a atenção, pois nao tinha trabalhado com linguagem natural e vi o quão grande fica a capacidade de uma rede entender cada palavra e no fim resultar em uma classificação.