**Relatório 23 - Prática: Reconhecimento de Emoções com TensorFlow 2.0 e Python (III)**

Matheus Beuren Carvalho

# 1. Introdução

Este relatório tem como objetivo descrever os principais conceitos e aprendizados contidos no curso de Visão Computacional designado a este card. Ao longo do desenvolvimento a maior parte foi colocada no treino de uma rede neural para o reconhecimento de emoções. A rede convolucional é a principal maneira de identificar as emoções em humanos, neste curso em questão ela é utilizada tanto para imagens quanto para vídeos.

# 2. Desenvolvimento

O reconhecimento de emoções se define pela identificação facial de um rosto para assim saber sua determinada emoção. A detecção de cada emoção é caracterizada pela identificação de características específicas de cada emoção, como exemplo a emoção de confusão, uma possível feature seria a pessoa franzir a testa.

Algumas de suas aplicações ao mundo real, são os carros autônomos, detecção de motoristas distraídos ou embriagados, na educação o reconhecimento de alunos confusos e na saúde identificando pacientes com enjoo.

Em primeiros passos, foi apresentado o conteúdo do curso(Reconhecimento de Emoções) e sua implementação na prática, que utilizou um modelo pré-treinado e uma imagem já vinda com o material de aula. A seguir será mostrado o treinamento de uma rede convolucional para o reconhecimento da emoção, junto com a definição de CNN.

A CNN abordada no curso se define pela rede convolucional padrão utilizada em outros cursos do Bootcamp. Consiste em quatro principais conceitos:

- Convolução: chamado de operador de convolução, ele tem um kernel que dado uma matriz LxC, essa matriz vai passar pela imagem(pixels) e filtrar as principais características;
- Funções de Ativação: aplicada após a convolução, ela troca os valores negativos por zero, o que evita uma informação irrelevante para a rede;
- Pooling: dado um kernel, retira a principal característica de uma região do feature map(o valor máximo);

- Flatten: transforma a matriz de pixels depois o pooling, em um vetor para que possa entrar como input na rede.

Na seção seguinte foi realizada a implementação de um modelo para detectar as emoções de faces humanas. Comparando a arquiteturas já vistas durante o bootcamp, essa sem dúvidas foi a mais complexa e que realmente é visto que a área de deep learning é bem complexa. No projeto desta seção foi implementado a arquitetura de um participante de uma competição no kaggle que conseguiu 63% de acurácia, um valor tecnicamente baixo porém satisfatório para o estudo de caso.

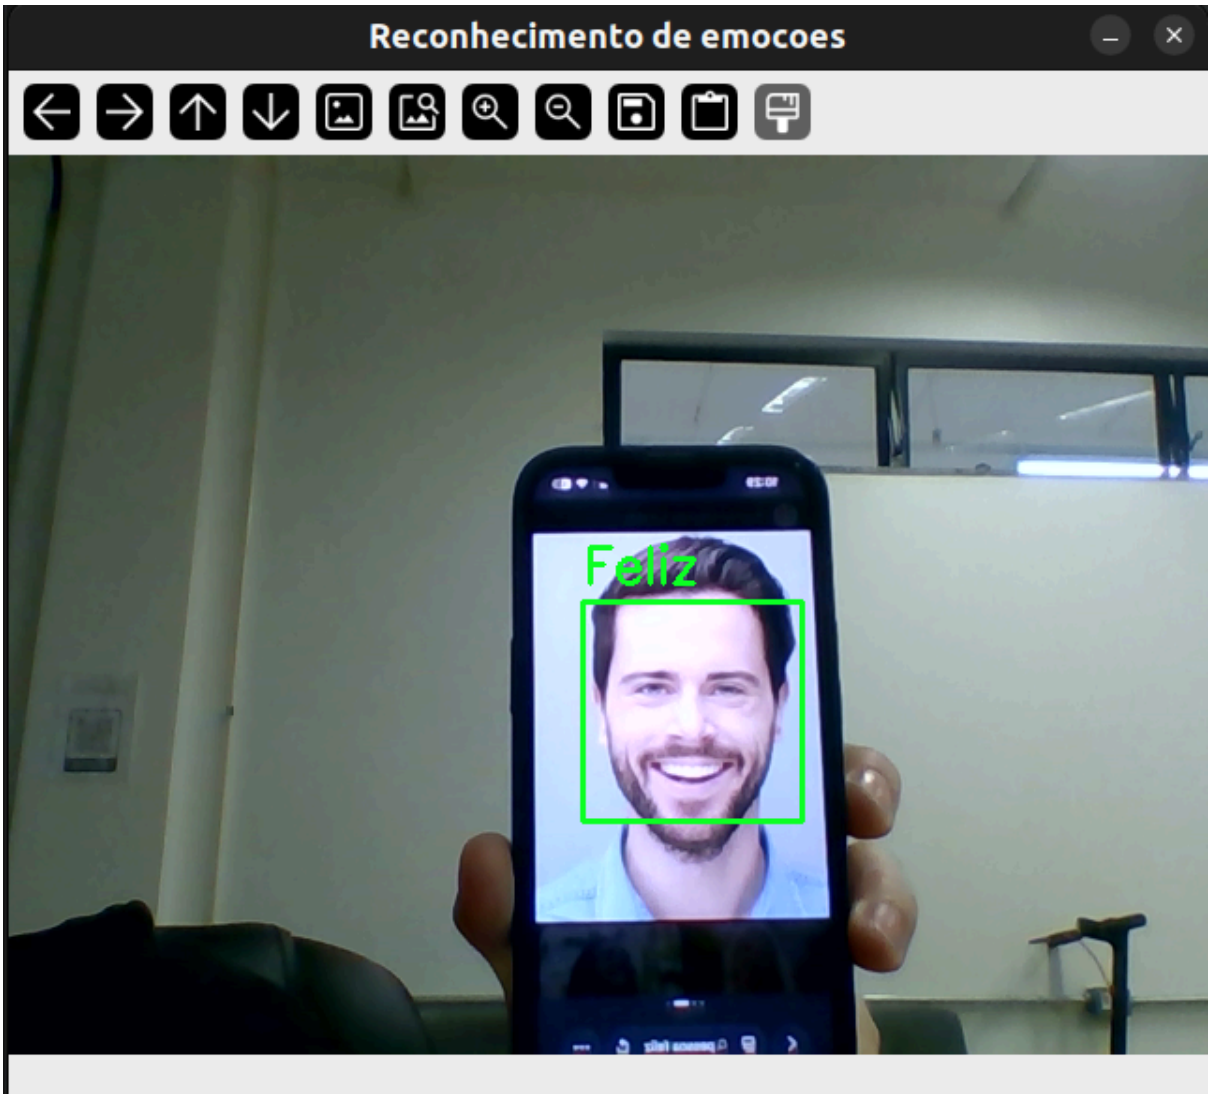
Algumas funções que são extremamente úteis para o desenvolvimento de redes neurais, aprendidas durante o curso são as:

- ReduceLROnPlateau: reduz o learning rate(aprendizado durante as épocas) se caso a rede não esteja mais aprendendo;
- EarlyStopping: após uma determinada sequência de épocas sem melhora no val_loss ele encerra o treino para evitar o overfitting;
- ModelCheckpoint: salva o melhor modelo até o momento durante o treino.

Em seguida, após terminar a implementação de uma rede neural para ser treinada, o curso abrange ainda mais o conteúdo aplicando o melhor modelo treinado a alguns vídeos. Nessa aula, era separado frame a frame os vídeos e assim o modelo podendo prediz a emoção das pessoas, depois juntando com o bounding box e a emoção a cada frame, obteve-se um vídeo com a emoção das pessoas presentes no vídeo. Nesse contexto, minha ideia para a prática desta seção é complexa, porém uma prática muito interessante. Nesta prática será feito o treino do modelo e será previsto a emoção da pessoa através de uma webcam em tempo real, diferente da aula onde é utilizado apenas vídeos pré-gravados.

O dataset escolhido para realizar a prática das aulas, foi o RAF-DB um dataset com imagens reais tiradas em ambientes naturais diferente do FER-13 que possui imagens de laboratório. Em vista da utilização deste dataset, ao analisar seu conteúdo pode-se observar é um conjunto de imagens desbalanceadas. Para resolver esse problema usei uma técnica para aplicar pesos às classes, fazendo o modelo aprender com peso menos para imagens que possuem mais réplicas e aprender menos para imagens de classes com poucas imagens. Também apliquei data augmentation pela pequena quantidade imagens no dataset, nisso foi colocado uma rotação aleatória para cada imagem.

**Figura 1 - Reconhecimento de emoções em vídeo**




A figura 1 evidencia a prática realizada para um modelo que detecta a emoção da pessoa através da webcam. O modelo utilizado para realizar as predições das emoções obteve 69% de acurácia em imagens de teste, uma acurácia baixa, porém não houve detecção de overfitting no modelo. As grandes limitações desta prática, é a pequena base de imagens que foi selecionada e também o desbalanceamento da própria.

Após o término da sessão de prática de rede neural, o conteúdo em seguida é uma revisão do que já tinha passado ao longo de alguns cursos do bootcamp. A seguir foi feita uma tabela para melhor compreensão desta seção.

**Tabela 1 - Tabela de revisão**

| Conceito | O que é |
|---|---|
| Função de Soma | Junta e faz o cálculo dos neurônios |
| Função de Ativação | Decide qual será a saída do neurônio |
| Cálculo de Erro | Mede a diferença entre o previsto e a resposta real |
| Gradiente | Mostra onde os maiores erros ou onde se concentra a maior parte dos erros dentro da rede |
| Descida do Gradiente | Algoritmo que aplica a otimização dos pesos em busca do menor nível de erro no gradiente |
| Cálculo do Delta | Representa o erro específico de um neurônio |
| Backpropagation | A rede “volta” da saída para entrada atualizando os pesos de cada camada para que seja diminuído o erro total |
| Bias(Viés) | Um neurônio de valor 1 conectado a todos os neurônios da camada de entrada, evita da soma sempre dar zero |
| MSE (Mean Squared Error) | Penaliza erros maiores ao elevar ao quadrado, elimina números negativos |
| RMSE | Raiz quadrada do erro médio |
| Learning Rate | Taxa de aprendizado a cada época da rede |
| Batch Size | Lote de dados que vão para o aprendizado da rede. |
| Epochs | Número de vezes que a rede vai ser treinada |
| Step Function | Retorna 0 ou 1 dado um limite que se ultrapassado ou que fique abaixo retorna um dos valores |
| Sigmoid | Retorna um valor contínuo entre 0 e 1 |
| Hiperbólica | Semelhante a Sigmoid, retorna em um intervalo de -1 a 1 |
| ReLu | Função que troca números negativos por 0, para positivos mantém o valor |
| Linear Function | Usado em problemas de regressão, retorna um valor contínuo(10.000) |
| SoftMax | Retorna uma probabilidade para cada classe, dado um problema de multiclasse |

# 3. Conclusão

O card desenvolvido fez a aplicação do conteúdo já estudado de redes convolucionais(CNN), aplicado a um dataset de imagens de pessoas, em vista de reconhecer a emoção da pessoa através de características de sua face. Este curso apresenta conceitos avançados referente a CNNs, e muito úteis na prática de visão computacional.