Relatório 26 - Prática: Métricas e Validação de Modelos de Aprendizado de Máquina (III)

Matheus Beuren Carvalho

1. Introdução

O desenvolvimento do card se resume na comparação de modelos e a utilização do shap, uma ferramenta que permite analisar as características que mais influenciam na predição de um modelo. Ao longo deste relatório, serão abordados os conceitos principais em relação aos vídeos vistos durante o desenvolvimento do card.

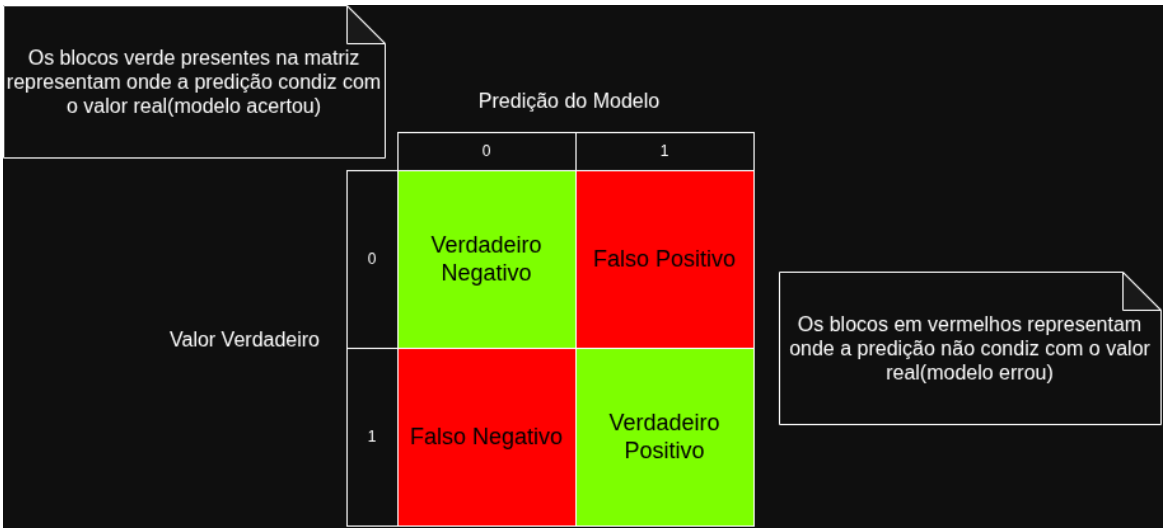
2. Desenvolvimento

O vídeo referente a comparação de modelos preditivos define dois tipos de modelos, como a classificação e a regressão. A classificação se baseia na rotulagem multiclasse ou binária, ou seja, prever se o estado atual de um objeto está em determinada classe. E a regressão é utilizada para prever valores numéricos, como por exemplo, prever o valor de uma casa com base em suas características.

Também é definido como o modelo aprendeu baseado em seus resultados nas base de teste, já com ele treinado na base de treino. Dito isso, é apresentado algumas métricas de avaliação de modelos.

A matriz de confusão é uma das métricas de avaliação mais eficientes e utilizadas para problemas onde é usado modelos de classificação. Na figura 1 é demonstrado o visual de uma matriz de confusão

Figura 1 - Matriz de confusão



Na figura 1, a matriz de confusão representa o desempenho de um modelo de classificação binária, onde dependendo do erro do modelo, pode prejudicar mais ou menos dependendo do problema a ser resolvido. Por exemplo, em um modelo que prediz se uma transação é fraude ou não, “Falso Negativo” prejudica mais que uma transação identificada como fraude. A tabela 1 aborda métricas que são usadas para avaliar um modelo de classificação.

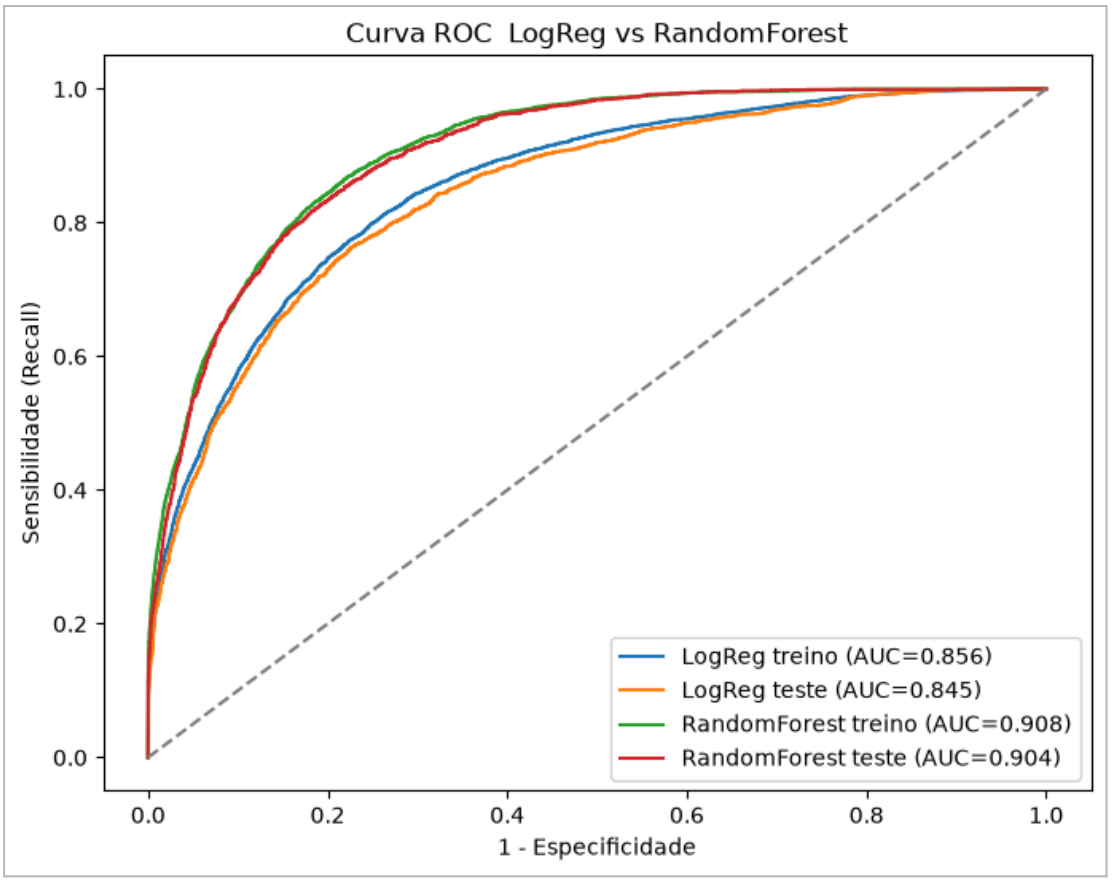
Tabela 1 - Métricas de Classificação

Nome	Fórmula	Descrição
Accuracy	$\frac{Acertos}{Total} = \frac{VN + VP}{VN + FN + VP + FP}$	Mede quanto o modelo acertou comparando a todos as previsões
Precision	$\frac{VP}{VP + FP}$	Quantas predições do modelo para uma classe não eram valores reais da classe
Recall	$\frac{VP}{VP + FN}$	Quantos registros de uma classe realmente foram capturados
Especificidade	$\frac{VN}{VN + FP}$	Quantos dos registros da classe oposta a de precision realmente foram classificadas corretamente

O cutoff é um corte feito na decisão de precisão em uma determinada classe, por exemplo, em um banco que deseja detectar fraudes, a classe ‘0’ significa ‘não fraude’ e a classe ‘1’ indica ‘fraude’, nisso o modelo errar uma transação dizendo que não era fraude uma que realmente era fraude é muito mais custoso que ao contrário, então o cutoff aumenta o corte de probabilidade de ser a classe fraude, assim obrigando que o modelo classificou como fraude onde há mais certeza de tal.

Nisso, o ROC se define pela curva onde é testado o modelo em diferentes cutoffs, tendo isso é gerado uma linha em um gráfico que permite-nos rastrear o desempenho do modelo pegando todos os acertos das duas classes. Na figura 2, o gráfico foi feito para comparar a curva ROC de dois modelos aplicados na mesma base de dados.

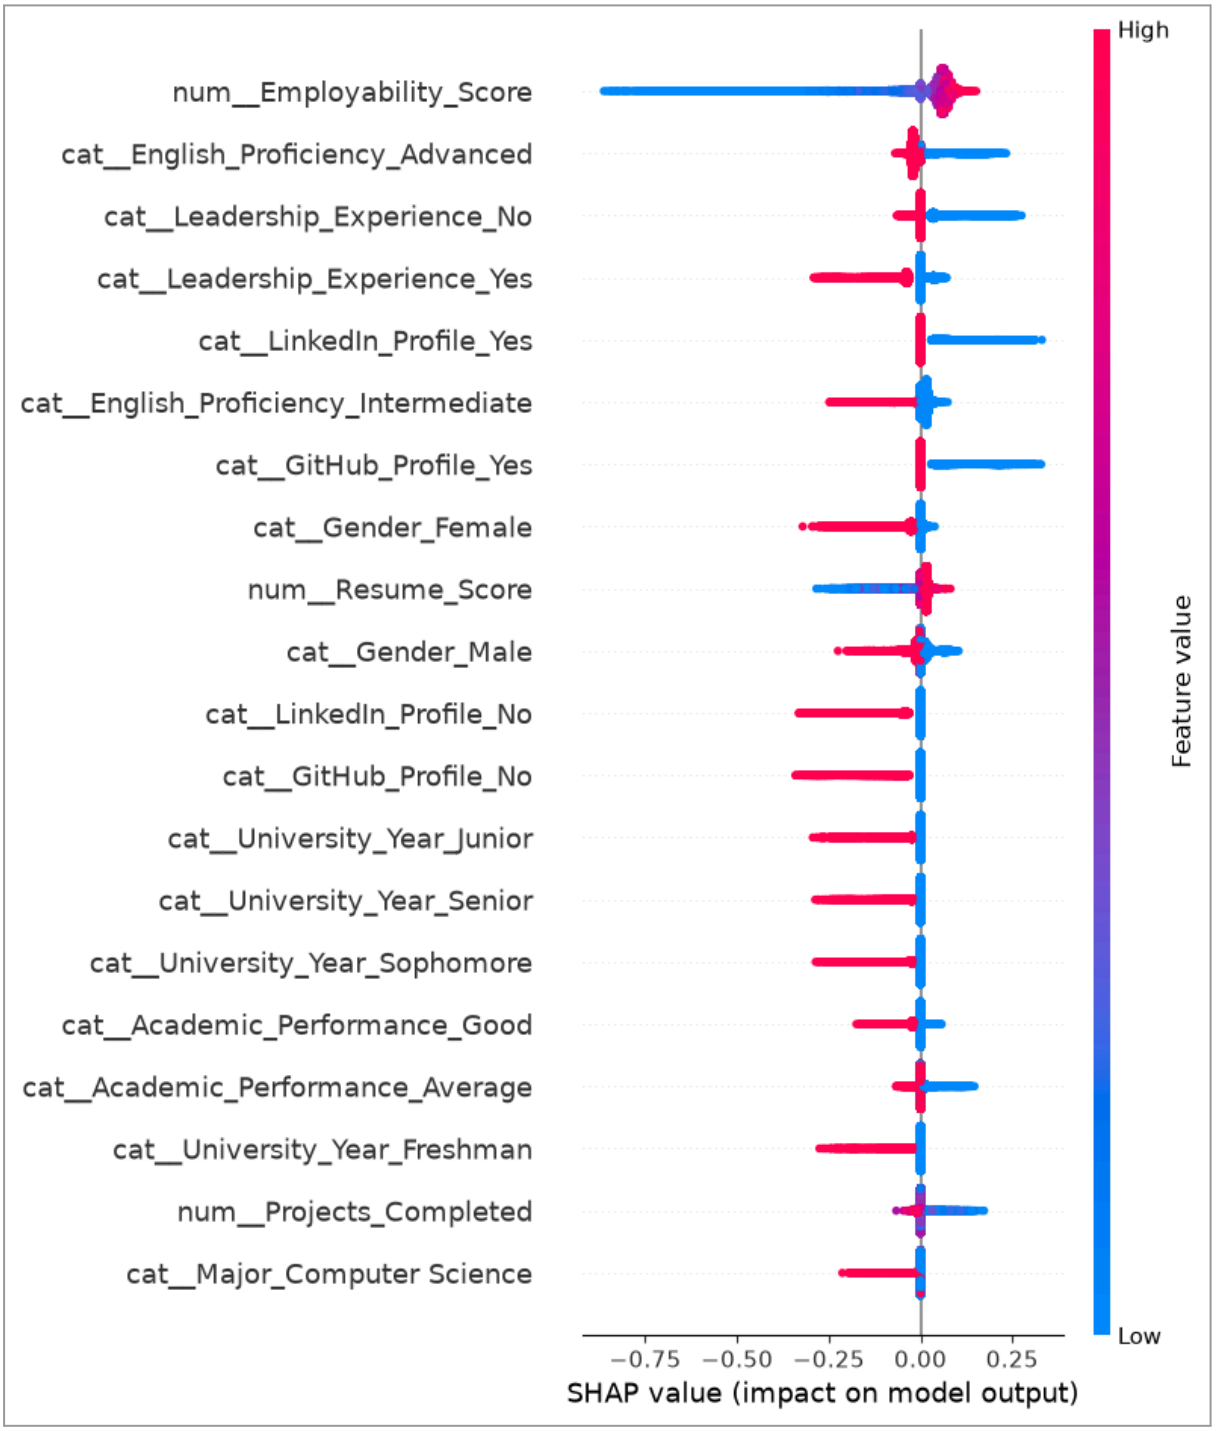
Figura 2 - Curva ROC e AUC



No gráfico da figura 2, observamos que há uma métrica chamada AUC, que significa a área abaixo da curva ROC. Quanto maior o AUC de um modelo, melhor ele é para classificar os dados. Nesse contexto, foram treinados dois algoritmos de classificação, regressão logística e random forest, com eles treinado e calculado a AUC podemos ver que o RandomForest teve o melhor desempenho em treino e teste.

O shap é um método que atribui para cada feature um valor de contribuição para a predição ou aprendizado de um modelo. Uma das funções pode ser vista na figura 3, onde as features que mais influenciam o modelo a tomar a decisão de predição ficam no topo e contém alguns pontos que são determinados pela influência na decisão do modelo.

Figura 3 - Plot Shap



Ao rodar o no dataset de estudantes, foi observado um vazamento de dados onde colunas como ‘Starting_Salary_USD’ e ‘Company_Tier’ não são características do aluno, mas consequências do resultado que o modelo deveria prever (quem não foi colocado tem salário zero automaticamente). O modelo aprendeu a depender quase só de ‘Starting_Salary_USD’ (importância 0,34 com o plot shap), enquanto

todas as outras features relevantes ficaram com importância zero. Isso mostra que o modelo não aprendeu nenhum padrão real sobre o perfil do aluno, só explorou uma coluna que já continha a resposta antes dele tentar prever.

3. Conclusão

Concluindo o desenvolvimento do card, foi apresentado o conteúdo central das aulas, como a comparação entre modelos e a utilização do shap. Foi comparado modelos para a representação das métricas, AUC e a curva ROC, onde foi definido um qual o melhor modelo pelas métricas apresentadas. E no treinamento do modelo foi analisado que um cenário de data leakage, que significa vazamento de dados, o modelo sabia que quando uma variável tinha um valor ‘0’ a resposta era ‘0’, assim fazendo o modelo acertar 100% de acurácia nos testes.