Proposta de Projeto Final Bootcamp de Aprendizado de Máquina - Lamia

Título do Projeto:	Segmentação Semântica Multiclasse de lesões em folhas de arroz
Nome do(a) Aluno(a):	Matheus Beuren Carvalho
Data da Proposta:	06/10/2026

Visão Geral e Problema

OBS: Criei a seção de referências, onde está o conteúdo que vou me basear para fazer o projeto

Resumo:	O projeto se baseia na ideia de um modelo que localizará, pixel por pixel, lesões nas folhas de arroz classificando-as em cinco classes(quatro lesões e uma classe para o fundo). A técnica de visão computacional usada, será a segmentação semântica de imagens, onde o objetivo é classificar a planta com base em sua característica física apresentada ao ter alguma doença.
Objetivo Principal:	O objetivo é treinar um modelo de segmentação semântica capaz de localizar pixel a pixel as lesões em folhas de arroz e classificá entre as quatro doenças consideradas (bacterial blight, blast, brown spot e tungro). Também avaliar a generalização do modelo em um conjunto de imagens

	externas, verificando se a doença predominante identificada na máscara prevista bate com o rótulo real da lesão na imagem.
Definição Detalhada:	Doenças nas folhas de arroz comprometem diretamente a produtividade da lavoura, e o diagnóstico tradicionalmente depende de inspeção humana, o que se torna lento e depende da experiência de quem avalia. A solução proposta é automatizar essa identificação a partir de uma foto da folha, localizando exatamente onde está a lesão e não apenas classificando a imagem inteira. A escolha do tema se justifica pela relevância para a agricultura de precisão em identificar lesões de forma rápida e localizando as lesões na folha, o que pode orientar decisões de manejo serem mais eficientes.

Dados

Fonte dos Dados:	Serão usados dois datasets da mendeley data: Rice Leaf Disease Image Samples, 5.932 imagens de quatro doenças de arroz e o RiceSeg-5932 é a base de máscaras do Rice Leaf Disease Image Samples. O Rice Leaf Disease Image Dataset for Multi-Class Disease Classification, tem 6.758 imagens em nove categorias, que inclui as quatro presentes nos datasets anteriores. Os dois primeiros datasets, correspondem às mesmas plantas, nisso será feita a junção das máscaras às suas respectivas folhas, e do terceiro será usado as classes que estão presentes no dataset de folhas que possuem máscara. Rice Leaf Disease Image Samples: https://data.mendeley.com/datasets/fwcj7stb8r/1

	RiceSeg-5932: Complete Pixel-Level Segmentation Masks for Rice Leaf Disease Images Samples: https://data.mendeley.com/datasets/92jc6w6mcy/1 Rice Leaf Disease Image Dataset for Multi-Class Disease Classification: https://data.mendeley.com/datasets/n8jpkpfz5p/1
Informações dos Dados:	As imagens das folhas são RGB, e as máscaras originais trazem a lesão em contraste com o fundo preto, de forma binária, ou seja, cada pixel marca lesão ou não lesão. As classes do modelo são: '0' para bacterial blight, '1' para blast, '2' para brown spot, '3' para tungro, e '4' para fundo/não-lesão, que representa tanto o fundo da imagem quanto a parte da folha sem lesão. Será feito um mapeamento para ligar cada imagem de folha à sua respectiva máscara, usando a nomenclatura do arquivo como referência. O dataset de lesões possui 5.932 imagens, com a mesma quantidade de máscaras associadas. Já o dataset de classificação, usado como teste externo, possui 6.758 imagens no total, porém serão utilizadas apenas 2.623, que correspondem às quatro classes de doença compartilhadas com o treino.

Metodologia

Domínio:	O projeto está relacionado à visão computacional, mais especificamente a uma área chamada segmentação, onde o objetivo é separar objetos de uma imagem, ou seja, extrair partes homogêneas de uma determinada imagem, ou vídeo. A

	técnica de segmentação utilizada foi a semântica, onde seu objetivo é classificar cada pixel da imagem com uma determinada classe. O motivo de não usar a segmentação de instância, que é uma técnica semelhante à semântica, é que para as folhas de arroz queremos saber onde está a mancha de lesão e qual doença ela representa, não quantas manchas distintas existem. Se fosse usada a instância, o modelo trataria por exemplo, duas manchas da mesma doença como dois objetos separados, com contorno e nomes próprios para cada uma, o que não agrega nada para o objetivo do projeto
Arquitetura(s):	U-Net e RESNET 50 aplicado a arquitetura U-Net(fine-tuning). O uso dessa rede já treinada(RESNET50) se define pela comparação em usar um modelo criado do zero e utilizar um modelo já treinado. Criado pela Microsoft Research, RESNET 50 é uma rede de cinquenta camadas já treinada na base de dados imagenet, e é amplamente usada em problemas de segmentação em bases médicas.
Métricas de Avaliação:	Na validação, pelas imagens de treino possuírem máscaras corretas, serão calculados Dice Coefficient(F1-score) e IoU, por doença(lesão). O IoU é uma das métricas mais utilizadas e ele compara o valor real da previsão do modelo, ou seja, ele pega a intercessão(o que os dois têm em comum) e divide pela área total dos dois(união). O Dice Coefficient mede o quanto a área prevista pelo modelo se sobrepõe na área real da classe(no caso da folha, a lesão), diferente da IoU que usa a união, o Dice multiplica por dois a intercessão para valorizar os acertos reais, e utiliza a área prevista somada à real para dividir pela intercessão. No teste externo, pela base não conter máscara de referência, a avaliação será feita comparando a doença predominante na máscara prevista com o rótulo da

	imagem, reportando acurácia, macro-F1 e matriz de confusão por doença.
Ferramentas e Bibliotecas:	Python, TensorFlow, OpenCV, NumPy, scikit-learn, e Matplotlib.
Possíveis Problemas:	Os principais riscos são que as classes podem estar desbalanceadas entre as quatro doenças e a qualidade das máscaras, pois o formato '.jpg' original tem compressão que pode corromper a borda da lesão(visto em uma exploração dos dados).
	O split treino e validação usar stratify por classe o que garante o balanceamento para separar os dados. As máscaras passam por binarização, antes do remapeamento, corrigindo o borrão do '.jpg'.

Resultados Esperados

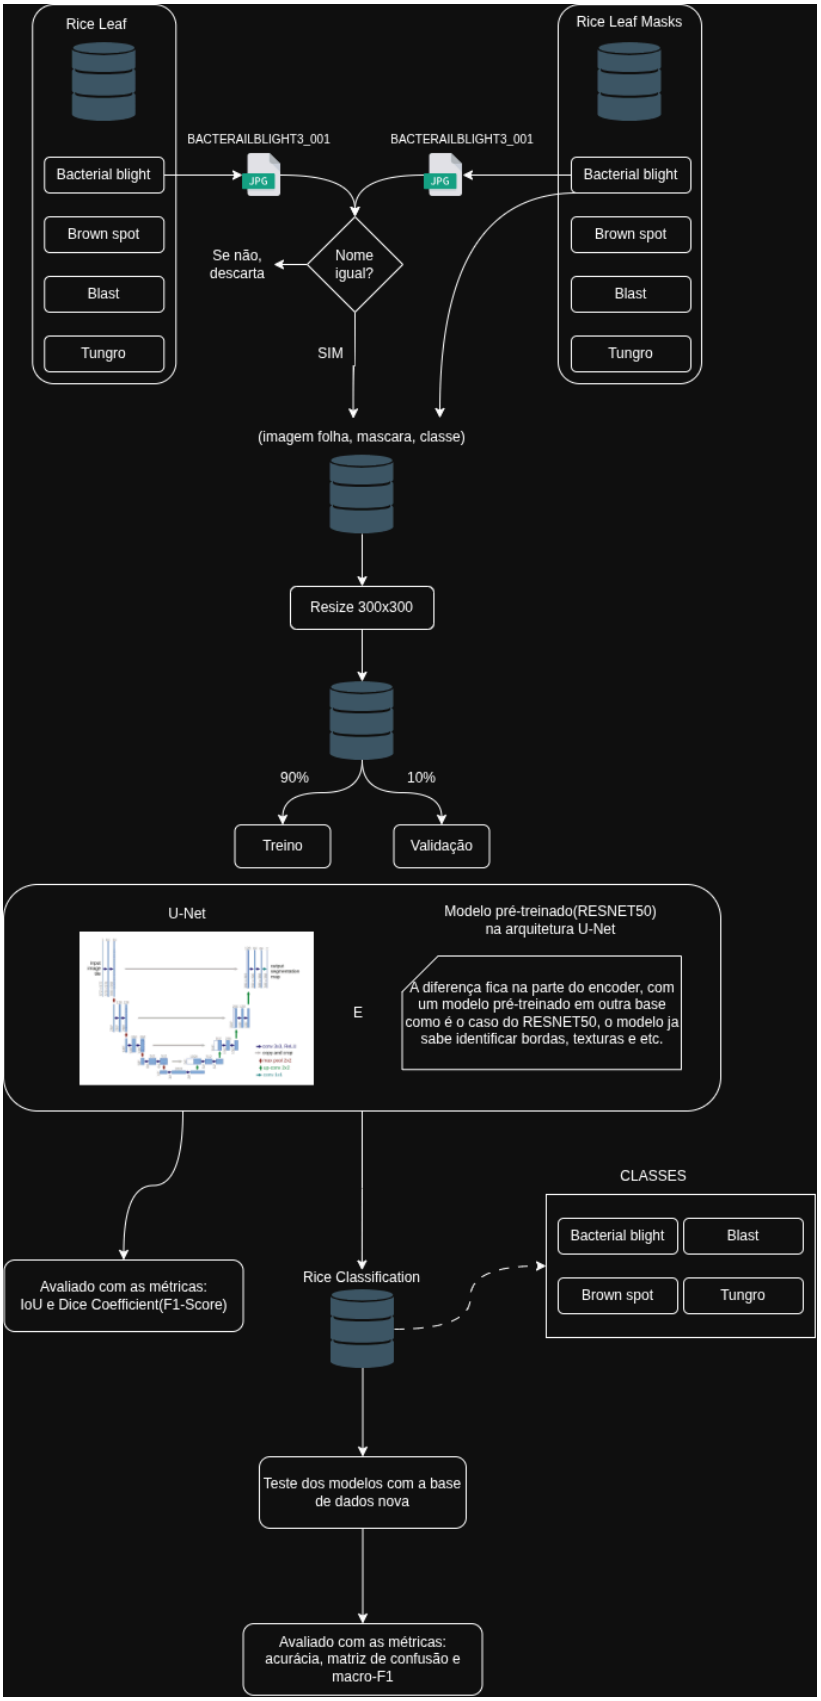
Métricas a serem atingidas:	Dice Coefficient e IoU médio > 0,70 na validação. Acurácia >70% no teste.
Saídas do Projeto	Modelos de segmentação treinados (U-Net do zero como base, comparada com fine-tuning da U-Net usando encoder RESNET50), notebook de pré-processamento, treino reprodutíveis, notebook de avaliação dos modelos, métricas

	de Dice e IoU por doença no treino, visualizações das máscaras previstas comparando com as imagens originais, e um relatório final discutindo os resultados alcançados e as limitações do projeto.

Justificativa

A proposta aborda um problema aplicado à agricultura de precisão e vai além de classificar a folha inteira, pois busca localizar as regiões lesionadas e classificá-la em quatro doenças conhecidas. RiceSeg-5932 informa máscaras pixel a pixel com 5.932 imagens. O estudo é viável por usar dados públicos e uma arquitetura já consolidada na área de visão computacional, o uso de um modelo pré-treinado, e abrange um conteúdo essencial na visão computacional que é a segmentação. A contribuição proposta é avaliar como a segmentação semântica multiclasse se comporta nos dados e a comparação entre um modelo criado do zero e o fine-tuning com um modelo pré-treinado.

Fluxograma do Projeto


Rice Leaf
Bacterial blight
Brown spot
Blast
Tungro
BACTERAILBLIGHT3_001
JPG
BACTERAILBLIGHT3_001
JPG
Rice Leaf Masks
Bacterial blight
Brown spot
Blast
Tungro
Se não, descarta
Nome igual?
SIM
(imagem folha, mascara, classe)
Resize 300x300
90%
10%
Treino
Validação
U-Net
Modelo pré-treinado(RESNET50) na arquitetura U-Net
E
A diferença fica na parte do encoder, com um modelo pré-treinado em outra base como é o caso do RESNET50, o modelo ja sabe identificar bordas, texturas e etc.
CLASSES
Bacterial blight
Blast
Brown spot
Tungro
Avaliado com as métricas: IoU e Dice Coefficient(F1-Score)
Rice Classification
Teste dos modelos com a base de dados nova
Avaliado com as métricas: acurácia, matriz de confusão e macro-F1

REFERÊNCIAS

Curso da Udemy, ele aborda a segmentação semântica:
https://www.udemy.com/course/segmentacao-imagens-python-a-z/?couponCode=KEEPLEARNING
Os códigos feitos no curso para segmentação semântica:https://github.com/beuren33/segmentacao-deep-learning

Vídeo sobre a arquitetura U-Net com RESNET50:https://www.youtube.com/watch?v=wYiJHFQ6f0Q

Papers:

Arquitetura U-Net: Ronneberger, O., Fischer, P., Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. In: Navab, N., Hornegger, J., Wells, W., Frangi, A. (eds) Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. MICCAI 2015. Lecture Notes in Computer Science(), vol 9351. Springer, Cham. https://doi.org/10.1007/978-3-319-24574-4_28

Segmentação multiclasse em folhas de plantas cítricas: Dinesh, P., Lakshmanan, R. Multiclass semantic segmentation for prime disease detection with severity level identification in Citrus plant leaves. Sci Rep 15, 21208 (2025). https://doi.org/10.1038/s41598-025-04758-y